



Porovnanie L^1 a L^∞ lineárnej regresie

- ▶ L^1 – veľmi dobre zachytáva lineárny vzťah, môže viesť k *overfittingu*
- ▶ L^∞ – príliš ovplyňovaná outliermi



Minimalizácia váženého súčtu noriem

- ▶ redukcia *overfittingu* L^1 regresie váženým súčtom s L^∞ normou

$$\min \omega \|y - \hat{y}\|_1 + (1 - \omega) \|y - \hat{y}\|_\infty, \quad \omega \in [0; 1]$$

- ▶ stále implementovateľné ako úloha lineárneho programovania

$$\min \left(\mathbf{0}_{k+1}^T \mid \omega \mathbf{1}_n^T \mid (1 - \omega) \right) \begin{pmatrix} \beta \\ t \\ \gamma \end{pmatrix}, \quad \omega \in [0; 1]$$

$$\left(\begin{array}{c|c|c} \mathbf{A} & \mathbb{I}_n & \mathbf{0}_n \\ \hline -\mathbf{A} & \mathbb{I}_n & \mathbf{0}_n \\ \hline \mathbf{A} & \mathbf{0}_{n \times n} & \mathbf{1}_n \\ \hline -\mathbf{A} & \mathbf{0}_{n \times n} & \mathbf{1}_n \end{array} \right) \begin{pmatrix} \beta \\ t \\ \gamma \end{pmatrix} \geq \begin{pmatrix} y \\ -y \\ y \\ -y \end{pmatrix}$$

Minimalizácia váženého súčtu noriem

► implementované ako `WeightedL1LInfModel`

