



Porovnanie L^1 a L^∞ lineárnej regresie

- ▶ L^1 - veľmi dobre zachytáva lineárny vzťah, môže viesť k *overfittingu*
- ▶ L^∞ - príliš ovplyňovaná outliermi



Minimalizácia váženého súčtu noriem

- ▶ redukcia *overfittingu* L^1 regresie váženým súčtom s L^∞ normou
- ▶ stále implementovateľné ako úloha lineárneho programovania
- ▶ nadobúda optimum

$$\min \left(0_{k+1}^T \mid \omega 1_n^T \mid (1-\omega) \right) \begin{pmatrix} \beta \\ t \\ \gamma \end{pmatrix}, \omega \in [0; 1]$$

$$\left(\begin{array}{c|c|c} A & \mathbb{I}_n & 0_n \\ \hline -A & \mathbb{I}_n & 0_n \\ \hline A & 0_{n \times n} & 1_n \\ \hline -A & 0_{n \times n} & 1_n \end{array} \right) \begin{pmatrix} \beta \\ t \\ \gamma \end{pmatrix} \geq \begin{pmatrix} y \\ -y \\ y \\ -y \end{pmatrix}$$

$$\beta \in \mathbb{R}^{k+1}, t \geq 0_n, \gamma \geq 0$$

Minimalizácia váženého súčtu noriem

► implementované ako `WeightedL1LInfModel`

